

# 基於語料庫的中文在線仇恨言論的統計研究

朴 敏 浚\*

## 〈 目 次 〉

1. 引言
  2. 研究方法
  3. 各領域的仇恨言論分析
  4. 反仇恨言論 (Counter Speech)
  5. 結論
- 參考文獻  
ABSTRACT

## 1. 引言

近年來，網路仇恨言論(hate speech)已成為嚴重的全球社會問題。儘管輿情監控從國家層面加強，但仇恨言論仍然成為互聯網文化的重要組成部分，針對特定性別、地域或國籍的嘲諷與攻擊性表達在社交媒體上依然傳播。

為了應對這一問題，自然語言處理(NLP)領域開始加強仇恨言論數據集的構建。目前，已有多個公開的中文仇恨言論語料庫，如COLD dataset(Deng et al., 2022)、CCL25-Eval10

---

\* 德成女子大學 中文系/軟件系 助教授

中文仇恨言論檢測數據(林鴻飛等, 2025)、SWSR(Jiang et al., 2022)和 PANDA(Bennie et al., 2025)等。另外, Xiao et al.(2024)對中文仇恨言論識別任務的現狀和評估標準進行整理, 提出了檢測模型。

儘管已有多個高品質的數據集, 但從語言學視角對中文仇恨言論的系統研究仍較匱乏。本研究旨在填補這一學術空白, 從語言結構與社會文化角度, 深入探討中國網路環境中的仇恨言論特徵, 通過語料庫分析揭示其主要模式及社會含義。

## 2. 研究方法

本研究基於語料庫的定量分析, 探討中文仇恨言論的語言特徵及其社會文化內涵。為此, 研究選定分析語料庫, 經過數據預處理後, 採用對數似然比(Log-likelihood Ratio, LL)進行關鍵詞特徵分析。

### 2.1 分析語料庫 (Dataset)

本研究所使用的語料來源於多個經人工校驗的在線評論和社交媒體文本集合。為了確保數據的代表性, 我們綜合利用了兩類主要資源: 一是以網絡評論為主體的 Chinese Online Language Database (COLD)<sup>1)</sup>; 二是由中國計算語言學大會(CCL25)公開的中文仇恨言論檢測數據<sup>2)</sup>。來源於知乎(Zhihu)和貼吧(Tieba)等社交網絡平臺, 綜合語料約含十八萬餘條評論與短帖, 覆蓋新聞、娛樂、社會議題等多種主題。所有樣本經人工去噪與語言篩選後, 按照表達對象與語用功能劃分為性別、族群與地域三大維度。這樣的多層劃分方式有助於揭示不同社會群體在網絡交流中的語言差異與情緒分布規律。

### 2.2 數據預處理 (Preprocessing)

1) <https://github.com/thu-coai/COLDataset>.

2) <https://github.com/DUTIR-Emotion-Group/CCL2025-Chinese-Hate-Speech-Detection>.

在文本清洗階段，研究首先對原始語料進行了格式統一與符號規整，包括刪除網址、表情符號及冗餘標點。之後使用基於概率統計模型的中文分詞系統進行詞語切分。為彌補系統對新興網絡詞彙識別率較低的不足，研究者在初步分詞後人工整合了用戶自定義詞典，其中涵蓋了網絡流行語、方言詞與社會群體稱謂等領域特定(domain-specific)語義單位，共計3,123個詞<sup>3)</sup>。

## 2.3 關鍵詞分析 (Keyword analysis)

借鑒於Stubbs(1995)和 Deng & Park et al.(2024)，本文利用對數似然比(Log-likelihood ratio, LL)對語料中的詞彙特徵進行提取。根據目標語料(Target corpus，如性別、種族、地域領域)與參照語料(Reference corpus，如整體仇恨言論語料)中詞語的出現頻率，計算 Log-Likelihood(LL)值，以確定哪些詞語與目標語料具有顯著關聯。具體而言，根據表1中的公式計算出的LL值，如果超過臨界值(Critical Value, 95%置信水平下為3.84,  $p < .05$ )，則拒絕“該詞彙的出現與文本之間沒有關係”的原假設，並判定該詞彙與文本之間具有統計顯著性，接受為該領域的詞彙特徵；反之，如果LL值未達到臨界值，則接受原假設，認為該詞彙不是該文本的詞彙特徵，即關鍵詞。

<表 1 對數似然比(LL)計算的基本原理 (Rayson et al., 2000; 2008)>

|           | 目標語料庫 (i) | 參照語料庫 (i) | 總計      |
|-----------|-----------|-----------|---------|
| 目標詞頻率 (O) | a         | b         | a+b     |
| 其他詞頻率     | c-a       | d-b       | c+d-a-b |
| Total (N) | c         | d         | c+d     |

$$LL_i = -2 \ln \lambda = 2 \sum_i O_i \ln \left( \frac{O_i}{E_i} \right), \text{ where } E_i = \frac{N_i \sum_i O_i}{\sum_i N_i}$$

如上所述，通過比較目標語料與參照語料的關鍵詞性(Keyness)，篩選出LL值超過臨界

3) 其中包括中文性別歧視語料庫(SWSR, Jiang et al., 2022)中的性別歧視詞表。

[https://github.com/\[匿名處理\]/HateSpeech/blob/main/zh/userdic\\_zh.txt](https://github.com/[匿名處理]/HateSpeech/blob/main/zh/userdic_zh.txt).

值的詞彙作為各領域的關鍵詞。例如，在表2的種族(race)領域，“美國”的LL值為295.01，顯著高於臨界值3.84( $p < .05$ )，因此被選為關鍵詞；而“法國”的LL值為2.27，未達到臨界值，因而未被納入研究範圍。

<表 2 各領域的詞彙特徵 (按關鍵詞性降序排列) >

| 領域 | 詞彙    | 關鍵詞性<br>(LL) | 目標語料庫(領域) |       | 參照語料庫(整體) |       |
|----|-------|--------------|-----------|-------|-----------|-------|
|    |       |              | 詞頻        | 相對頻率  | 詞頻        | 相對頻率  |
| 性別 | 直男癌   | 131.86       | 151       | 0.14% | 221       | 0.04% |
|    | 女權    | 115.39       | 278       | 0.25% | 657       | 0.11% |
|    | 女拳    | 32.43        | 63        | 0.06% | 133       | 0.02% |
|    | 綠茶    | 6.65         | 6         | 0.01% | 7         | 0.00% |
|    | ..... | .....        | .....     | ..... | .....     | ..... |
|    | 評論    | 2.85         | 66        | 0.06% | 279       | 0.05% |
| 種族 | 黑人    | 1690.32      | 6610      | 2.29% | 6697      | 1.12% |
|    | 美國    | 295.01       | 1401      | 0.49% | 1526      | 0.26% |
|    | 亞裔    | 249.24       | 970       | 0.34% | 975       | 0.16% |
|    | 國家    | 60.47        | 436       | 0.15% | 544       | 0.09% |
|    | ..... | .....        | .....     | ..... | .....     | ..... |
|    | 法國    | 2.27         | 24        | 0.01% | 33        | 0.01% |
| 地域 | 井蓋    | 315.88       | 550       | 0.28% | 558       | 0.09% |
|    | 外地人   | 249.54       | 441       | 0.22% | 452       | 0.08% |
|    | mmp   | 30.01        | 54        | 0.03% | 56        | 0.01% |
|    | 優越感   | 26.76        | 87        | 0.04% | 125       | 0.02% |
|    | ..... | .....        | .....     | ..... | .....     | ..... |
|    | 用     | 1.74         | 191       | 0.10% | 517       | 0.09% |

由此可見，對數似然比(Log-likelihood ratio, LL)指標在各個語料庫規模不同以及功能詞(function words)高頻出現的情況下，對於代表文本特徵的詞彙，即仇恨言論領域特定的關鍵詞抽取(keyword extraction)起著至關重要的作用。在大規模仇恨言論語料中，研究者無需逐一分析所有詞彙，而是通過基於上述統計檢驗的定量分析方法，能夠有效地提取出各領域仇恨言論的主要關鍵詞。隨後，通過進一步聚焦這些提取出來的關鍵詞及其上下文(KeyWord In Context, KWIC)，本研究將更精準地分析仇恨言論在不同領域中的語言使用特徵及其社會文化內涵。

### 3. 各領域的仇恨言論分析

本章基於2.3節的關鍵詞分析法，提取了性別、種族和地域三個領域(domain)的詞彙特徵，並對這些詞彙的典型使用方式進行質性考察。

#### 3.1 性別分歧與仇恨言論

在性別仇恨言論中，代表性的關鍵詞(keywords)包括“直男癌、渣男、女拳、綠茶”等。這些詞彙的關鍵詞性評分(LL)排名靠前，通過塑造負面刻板印象，加深了對特定性別與群體的偏見，廣泛用於表達對其他群體的敵意。

<表 3 性別領域的關鍵詞提取結果(按關鍵詞性降序排列)>

| 關鍵詞 | 排名  | 性別仇恨領域詞頻 | 全領域詞頻 | 關鍵詞性(LL) |
|-----|-----|----------|-------|----------|
| 男人  | 2   | 1152     | 1461  | 1181.658 |
| 女人  | 3   | 1074     | 1392  | 1076.945 |
| 女生  | 7   | 381      | 528   | 354.458  |
| 男生  | 8   | 301      | 366   | 320.829  |
| 惡心  | 10  | 838      | 2303  | 245.642  |
| 出軌  | 11  | 195      | 206   | 236.436  |
| 直男癌 | 14  | 151      | 221   | 131.864  |
| 女權  | 16  | 278      | 657   | 115.393  |
| 直男  | 21  | 80       | 93    | 88.946   |
| 渣男  | 28  | 59       | 73    | 61.751   |
| 女拳  | 49  | 63       | 133   | 32.431   |
| gay | 50  | 37       | 54    | 32.401   |
| 約炮  | 56  | 27       | 32    | 29.468   |
| 男同  | 62  | 28       | 37    | 27.386   |
| 基佬  | 143 | 14       | 20    | 12.566   |
| 娘炮  | 269 | 10       | 17    | 7.217    |
| 綠茶  | 291 | 6        | 7     | 6.646    |

在網絡語境中，性別仇恨言論的關鍵詞主要圍繞男性的刻板印象和對女性的貶損展開。

針對男性，“直男”和“直男癌”常用於諷刺封建保守、思維刻板的男性。“渣男”指不道德的男性，“娘炮”還用於批評被認為缺乏男子氣概或經濟獨立性的男性。然而，部分男生反駁這種標籤化表達，認為“渣男”的定義帶有選擇性，甚至在某些語境中帶有對男性的不公平評價(例4、5)。另一方面“基佬、男同、gay”(同性戀者)則用於討論男性的不忠行為或性取向，有時也帶有貶低同性戀群體的意味。例如：

- (1) 有的男生不是直男，是沒文化。  
(部分男性并非傳統意義上的“直男”，而是缺乏文化素養。)
- (2) 為什麼是爸爸做飯，你這是直男癌，試圖誤導別人以為女性不出力。
- (3) 渣男！估計是個超級娘炮吧...男人自己再苦不到不得已絕對不會向女人伸手要錢！
- (4) 現在才感嘆中國女權給力啊。要是男方出軌，早就噴人渣，渣男，騙子，淨身出戶。
- (5) 濫交無罪出軌有理？換成男的是這個反應，你還會這樣講？
- (6) 基佬也想要娶女人？
- (7) 看到男同又覺得惡心。很討厭濫交gay或者說騙子宮的那種男的。

針對女性的性別貶損詞彙，“女拳”(諷刺女權主義者過度維護女性權益)和“綠茶”(嘲諷表面清純但內心算計的女性)最為突出。其中，“女拳”是“女權”的諧音，用於貶低女性主義者，而“綠茶”則利用雙重含義(清新與苦澀)隱喻女性的兩面性。此外，“綠茶”不僅作為名詞使用，還可以在句子中當作謂詞性成分使用(例9)。例如：

- (8) 動不動就中年油膩男。田園綠茶女拳挨過這麼多炮火還裝純真的，夠惡心。
- (9) 被自己不愛的男人一直追求，還是很恐怖吧，死纏爛打最討厭了。當然，讓自己不愛的男人幫自己追愛的人，這很綠茶，很婊。

可以看出，性別仇恨言論主要圍繞男性的固有刻板印象(如“直男癌、渣男”)和女性的行為(如“綠茶、女拳”)展開。這些詞彙通過諷刺、隱喻和諧音的方式，強化了網路空間中的性別對立，並在社交媒體平臺上廣泛流通。

### 3.2 種族/國籍分歧與仇恨言論

種族與國籍仇恨言論主要圍繞“黑人、中國、歧視、美國、日本”等關鍵詞展開。這些詞

彙在關鍵詞性評分(LL)中位列前茅，主要用於批判外國對中國人的歧視案例，或表達對特定國家和種族的負面情緒。

<表 4 種族/國籍領域的關鍵詞提取結果(按關鍵詞性降序排列)>

| 關鍵詞 | 排名 | 性別仇恨領域詞頻 | 全領域詞頻 | 關鍵詞性(LL) |
|-----|----|----------|-------|----------|
| 黑人  | 1  | 6610     | 6697  | 1690.320 |
| 中國  | 3  | 2661     | 3305  | 377.255  |
| 白人  | 4  | 1332     | 1360  | 330.146  |
| 歧視  | 5  | 3638     | 5069  | 327.041  |
| 美國  | 6  | 1401     | 1526  | 295.014  |
| 亞裔  | 7  | 970      | 975   | 249.237  |
| 黃種人 | 9  | 377      | 379   | 96.696   |
| 華人  | 10 | 336      | 350   | 79.137   |
| 印度人 | 12 | 288      | 299   | 68.383   |
| 種族  | 13 | 275      | 286   | 65.016   |
| 非洲  | 14 | 252      | 256   | 63.049   |
| 國家  | 15 | 436      | 544   | 60.474   |
| 日本  | 19 | 370      | 470   | 48.124   |
| 華裔  | 25 | 153      | 158   | 36.793   |
| 日本人 | 27 | 233      | 289   | 32.973   |
| 亞洲  | 30 | 130      | 138   | 29.185   |
| 犯罪  | 31 | 205      | 254   | 29.115   |
| 韓國  | 40 | 196      | 251   | 24.731   |

在所有仇恨言論中，“黑人”是最主要的攻擊對象，共出現6610次。其中，“歧視黑人”這2-gram的出現頻率高達855次，遠高於“喜歡黑人”(125次)。甚至在“喜歡黑人”這125次的使用中，有108次實際上是否定表達(如“不喜歡黑人”)，剩餘的表達也大多帶有貶義色彩，如例(13)：

- (10) “黑人的平均智商低”是一個客觀事實
- (11) 我不歧視黑人，前提是他不來中國。
- (12) 反正黑人和印度人是我感覺體味最大的。
- (13) 黑人是昆侖奴，醜是真醜，有誰喜歡黑人的顏值啊。
- (14) 最該抵制的其實是非洲黑人！看看他們在美國的犯罪率以及因為種族矛盾而給美國帶來的動蕩和撕裂，簡直讓人不寒而栗。

這些言論顯示了網路社區中對黑人的普遍刻板印象，如低智商、不衛生等，同時也體現了網民對特定族群的持續性貶低。除此之外，網民在國籍和種族問題上高度關注海外華人受到的歧視，尤其是“華人、亞裔、中國人、亞洲人”等詞頻較高。例如：

- (15) 爲啥是中國人有種族歧視。。我老覺得好像是全世界歧視中國人。。
- (16) 美劇里面歧視亞裔的真的超級多，在他們眼里我們都是那種除了勤奮一無是處的  
    傻人
- (17) 加拿大歧視華人也沒人管。
- (18) 打得好，這要是黑人他絕對不敢這麼放肆。這就是白人歧視亞洲人，該揍。
- (19) 在澳洲華裔面孔=被歧視，華人拿到永居孩子照樣被歧視。

這些言論反映：中國網民認為華人在國際社會中受到不公正待遇，並普遍持有受害者心態。這種討論往往帶有集體主義傾向，強調“集體強大才能避免歧視”的觀點，比如：

- (20) 黑人不歧視日本和韓國人，唯獨歧視中國
- (21) 只有祖國強大了才是真理，如果現在中國能在太平洋多弄幾個航母編隊，看看哪  
    個國家敢歧視華人？
- (22) 居然還敢瞧不起我們黃種人，黃種人將主宰世界

在涉及具體國家的仇恨言論中，“美國、印度、日本、韓國”是最常被提及的對象。這些國家常常因為政治、歷史、文化差異成為攻擊對象，並且相關言論不僅是對該國的簡單貶低，更折射出網民對國際社會中祖國地位的關注，以及通過網路話語構建民族認同的傾向。

- (23) 美國就是得反思一下，爲啥世界上85%的國家都把其列爲最不受歡迎的國家。
- (24) 印度人會抱團又懂得討好美國人，技術水平却不咋地，不少華人都說了公司里的  
    印度人不做實事。
- (25) 印度人是最沒有節操最惡心的民族。
- (26) 日本真的是一個變態的國家，日本是永遠都需要棍棒教育的國家。
- (27) 日本的愛國主義大多都帶着種族歧視和排斥意識，他們會因為自己是日本人而非  
    常驕傲，認為自己是最崇高的民族，所以常常看不起其他國家。
- (28) 韓國是個極其落後，極其糟糕的國家，所以我爺爺奶奶才會選擇移民美國。
- (29) 韓國動不動就說中國節日是他們的！來源於他們國家！



這些言論不僅涉及對外部群體的不滿，更經常將個人層面的矛盾上升到國家層面的對立，甚至通過網路言論強化民族身份認同，從國際競爭和民族地位的角度普遍關注國際關係中的對立，強調國家在國際競爭中的地位。可見，種族與國籍仇恨言論在社會意識形態中佔據重要地位。

### 3.3 地域分歧與仇恨言論

由於中國幅員遼闊，民族衆多，不同地區之間的差異在經濟、文化等多個維度上呈現。地域仇恨(俗稱“地域黑”)往往通過賦予特定地區或群體刻板印象和負面標籤，在網路空間中以特定關鍵詞和表達方式加以體現。

<表 5 地域領域的關鍵詞提取結果(按關鍵詞性降序排列)>

| 關鍵詞 | 排名 | 性別仇恨領域詞頻 | 全領域詞頻 | 關鍵詞性(LL) |
|-----|----|----------|-------|----------|
| 河南人 | 1  | 1158     | 1190  | 654.175  |
| 河南  | 3  | 743      | 762   | 420.430  |
| 地域  | 4  | 773      | 827   | 411.047  |
| 東北人 | 6  | 654      | 670   | 370.545  |
| 東北  | 7  | 581      | 605   | 321.435  |
| 井蓋  | 8  | 550      | 558   | 315.876  |
| 黑   | 9  | 927      | 1306  | 298.831  |
| 偷   | 10 | 474      | 498   | 258.741  |
| 臺灣  | 12 | 404      | 425   | 220.067  |
| 山東  | 13 | 350      | 365   | 193.082  |
| 臺灣人 | 14 | 318      | 325   | 180.613  |
| 四川人 | 15 | 294      | 294   | 172.183  |
| 山東人 | 17 | 275      | 276   | 160.232  |
| 新疆  | 18 | 275      | 284   | 153.845  |
| 素質  | 19 | 496      | 764   | 129.272  |
| 排外  | 22 | 213      | 225   | 115.250  |
| 香港  | 23 | 221      | 241   | 113.945  |
| 落後  | 28 | 231      | 294   | 91.422   |
| ... | 29 | 745      | 1465  | 87.738   |
| 內地  | 56 | 59       | 61    | 32.931   |
| 優越感 | 72 | 87       | 125   | 26.764   |
| 殺人  | 93 | 126      | 232   | 19.126   |

河南是地域歧視最嚴重的地區之一，關於河南人的偏見和謠言廣泛流傳，尤其是“河南人偷井蓋”的刻板印象尤為突出。河南相關的仇恨言論多基於經濟落後、素質低下以及偷竊等負面印象。

(30) 我們河南人都沒有職業的，我們河南人的職業就是天不亮就偷井蓋的。

(31) 河南人素質低，這是大家都知道的，特別這口音听得想吐。

針對東北的仇恨言論主要集中在東北方言、暴力傾向等方面。“東北人”一詞被不合理地與暴力、魯莽和低文化素質聯繫在一起。

(32) 東北人就是直爽，覺得好欺負就死命欺負，從來不講道理。

(33) 東北人說話口音不要太明顯好嗎。

由於新疆的民族和宗教特徵，該地區經常成為仇恨言論的對象。新疆人被描繪為暴力、非法行為和衛生條件差的群體：

(34) 新疆室友坐在自己的桌子前面擦水果刀，表情陰冷。“你們知不知道我們新疆人一輩子有一次殺人判刑的機會。”

(35) 我也被新疆人搶過，為啥我會知道是新疆人啊，長相應該就是新疆的。

地域仇恨言論不僅僅針對經濟落後的地區，經濟發達的地區也會因文化特點而成為批判的對象。例如，山東因其儒家文化背景，被批評為重男輕女的代表：

(36) 山東人感覺受儒家文化影響確實特別深，並且以前的父輩大男子主義，重男輕女是有的，這不能否認。

四川的仇恨言論則集中在方言和日常交流方式上，尤其是“mmp”等詞彙被視為四川話的典型代表：

(37) 我在四川上大學，都是四川人一口一個mmp，老實說，四川人罵人的話特髒。

臺灣和香港作為特殊行政區，其仇恨言論主要基於歷史差異。例如，臺灣的仇恨言論主

要集中在“優越感、排外態度”上：

- (38) 臺灣盲目樂觀，看不到大陸發展，臺灣早就落後於大陸，臺灣人還有蜜汁優越感。
- (39) 臺灣人是真的酸，他們認為自己90年代一直是亞洲四小龍之首。
- (40) 哪裡都有歧視的…我們就連同個國家的香港還歧視我們內地人呢。
- (41) 拿香港比作非暴力不合作，你是在侮辱解放軍嗎？

這些言論反映了香港與內地之間的文化與政治差異，並強化了“內地人與港臺人對立”的敘事。

另一個值得注意的現象是，地域仇恨言論中省略號(“…”)的頻繁使用。這種表達方式表面上表現為含蓄和謹慎，但實際上仍然隱含了地域歧視的意味：

- (42) 最近黑福建的兄弟比較多我也就不裝逼了……就這麼比吧，福州和重慶？呵呵呵呵。
- (43) 旁邊的托不想事大說撿到了我剛掉的錢，又給我補回了……媽的噁心……山東某地方車站……
- (44) 兄弟……問題是騙子是哪人你都不知道啊……

省略號的使用在一定程度上避免了直白的攻擊，使得言論更具諷刺意味，同時也是一種策略，讓讀者自行填補潛在的負面評價。這反映出，跟性別、種族或國籍等議題相比，地域攻擊往往更加隱晦謹慎，不直接表達。這可能是因為地域歧視的傳播者與受眾之間的社交距離較近，甚至可能是現實生活中的朋友、同事或社交圈內的人，因此公開表達敵意或極端言論可能帶來直接的衝突。因此，在地域歧視的表達中，網民往往選擇使用更委婉、迂迴的方式，而非直截了當的攻擊性言論。

總體而言，地域仇恨言論反映地域特徵、社會背景、經濟水平以及文化差異，表現出不同的表達方式。資源分布不均的地區如河南、東北與新疆，通常被刻板印象化為貧窮、低素質或暴力傾向；山東和四川，則因其文化或方言特徵而受到批評。臺灣和香港的仇恨言論更多涉及區域優越感。省略號的使用則體現了網民在地域仇恨表達上的策略性迴避。這些現象說明，地域仇恨的表達方式和強度根據具體的社會情境呈現有所不同，跟性別和種族仇恨言論相比更加隱晦含蓄。

## 4. 反仇恨言論 (Counter Speech)

如前文所述，網路仇恨言論助長了針對特定群體的偏見和排斥。這些言論由於缺乏客觀依據，在重複傳播的過程中不斷放大，形成刻板影響的惡性循環。然而，在大量仇恨言論的喧囂中，仍然存在一些理性的反駁和反思的聲音。這類反仇恨言論不僅質疑仇恨言論的合理性，還通過邏輯推理指出其論證漏洞，並借助事實性分析揭示其誇大或誤導成分。

### 4.1 反仇恨言論的語言策略

反仇恨言論是：針對仇恨言論的積極、理性且有說服力的回應。這不僅僅是對仇恨言論的簡單反駁，更是一種旨在抑制其傳播、維護社會和諧的語言策略。

- A. 邏輯反駁(Logical Refutation)：通過邏輯推理反駁仇恨言論，指出其論證漏洞。
- B. 積極重構(Positive Reinterpretation)：對攻擊性言論進行溫和調整，減少不必要的對立情緒。
- C. 事實回應(Fact-Based Response)：利用客觀數據或證據進行事實性反駁，削弱仇恨言論的影響力。

<表 6 反仇恨言論的不同應對方式>

| 仇恨言論<br>(Hate Speech) | 反仇恨言論<br>(Counter Speech)            | 應付策略 |
|-----------------------|--------------------------------------|------|
| 韓國是個極其落後，<br>極其糟糕的國家  | 每個國家都有自己的優勢和挑戰，不能以偏概全。               | 邏輯反駁 |
|                       | 如果一個‘落後’的國家能在短短幾十年內崛起，那它的成功經驗值得借鑒。   | 積極重構 |
|                       | 我去韓國旅遊時，發現基礎設施非常現代化，公共交通很高效，服務也熱情周到。 | 事實回應 |

## 4.2 邏輯反駁

這一類型的反仇恨言論直接指出仇恨言論的邏輯漏洞，並通過揭示其矛盾性來駁斥刻板印象和偏見。

- (45) 臺灣人都是詐騙犯？上海人都小氣？北京人都老炮？廣西人都愛砍人？地圖炮就不對了吧
- (46) 一個東北人打人就可以說整個東北三省的人素質低，照你這麼說，每個省市都有殺人犯，全中國都特麼是殺人犯啊

上述例子明確指出了仇恨言論中以偏概全的錯誤，並強調個體行為不能代表整個群體。此外，某些仇恨言論在批判特定群體的同時，又反對自身群體被歧視，這種雙重標準也常被邏輯反駁所揭示：

- (47) 一邊罵著白人歧視華人，一邊理所當然地歧視黑人。人啊，都是一樣的，沒有誰比誰更高尚。
- (48) 歧視黑人在世界各地都是不應該的，就像你在一個白人國家被歧視你是黃種人，你覺得應該嗎？

這些言論表明，種族歧視無論針對哪個群體都是不正當的，指出持有歧視性態度的人往往忽視自身在某些情況下也可能成為受害者。

## 4.3 積極重構

另一類反仇恨言論並不直接反駁仇恨言論，而是通過溫和的方式重新定義其含義，用以減少對方的敵意，促進對立觀念之間的理解與包容。

- (49) 很多四川人的mmp都只是口頭用語而已啊。
- (50) 何必要標明新疆人呢，直接用小偷代替不就好了。作為新疆人表示收到了傷害
- (51) 爲啥大家都說東北人說話像吵架，我聽著賊有喜感了，我唐山人，在武漢讀書，同學們說我說話一股東北味，還特別親切，各位說東北人說話像吵架的聽過武漢大媽嘮嗑不？只能說是相當彪悍了

這些例子通過調整表達方式來弱化偏見，促進理解的溝通。例如，例(49)指出某些地域方言中的特定表達僅是日常口頭用語，並無實際攻擊性，從而緩解對該地區語言的誤解。例(50)指出，直接點名地域可能引起刻板印象，因此避免特定地域標籤有助於消解偏見。例(51)通過強調東北話的幽默感，打破了“東北人說話像吵架”的刻板印象，改變人們對其負面認知。

#### 4.4 事實回應

事實回應通過提供客觀數據或個人經驗來糾正仇恨言論中的誤導性資訊。這種策略既能避免爭論，又能有效削減仇恨言論的影響。

- (52) 如果去臺灣旅遊，那邊服務業人員大多還是很熱情的，臺灣罵大陸基本都是在網上的年輕人和恰爛錢的政治評論員，線下臺灣人民還是蠻禮貌。
- (53) 我是內蒙人，在福建上學，身邊的福建同學很好，能力很強，學習也好
- (54) 爲什麼叫這個男的渣男？渣男的定義是什麼？渣男不是玩弄女性的感情或者身體嗎？還是窮就是渣？還是小氣吝嗇就是渣？

例(53-54)指出網路上的刻板印象往往與現實經歷不符，揭示了某些偏見的片面性，並提供了更加均衡的認知視角。例(52)則強調某些標籤化表達帶有選擇性，批評“渣男”含義模糊且易被濫用，因此應該明確界定術語，以防加深社會偏見。

#### 4.5 反仇恨言論的挑戰與髮展方向

儘管反仇恨言論在遏制仇恨言論方面起到一定的作用，但在當前網路環境下，其數量遠少於仇恨言論。因此，光靠個人的自發表達難以有效對抗，更爲可行的方式是建立反仇恨言論語料庫，在此基礎上開發自動化的反仇恨言論生成系統。

然而，由於反仇恨言論在修辭和語義上的複雜性(如諷刺、反諷、隱喻等)，其內容往往容易被誤判爲仇恨言論。實際上，本節提供的多個示例也在COLD Dataset 和 CCL25-Eval10 語料庫中均曾被誤標爲仇恨言論的。這表明，即便是人工標註，準確識別仍然存在挑戰。因此，未來的研究應著重完善仇恨言論與反仇恨言論的區分，用以有效抑制仇恨言論的擴散，

同時促進反仇恨言論的良性發展。本節提出的“邏輯反駁、積極重構、事實回應”的三種模式，可為未來的反仇恨言論研究提供有價值的參考。

## 5. 結論

本文基於大規模語料庫分析，系統探討了中文網絡仇恨言論在性別、種族/國籍、地域三個維度的表達模式及其語言特徵。研究結果表明，不同類型的仇恨言論在關鍵詞使用、語境特徵、社會文化背景上存在顯著差異。

首先，性別仇恨言論主要圍繞社會性別角色展開，通過標籤化用語塑造對男性的刻板印象；“女拳、綠茶”等詞彙則用於描繪特定女性群體，顯示出網絡空間中性別議題的突出表達。其次，在種族與國籍相關的言論中，部分內容展現出較強的群體意識，不儘涉及對外部群體的固有印象，也包含關於跨文化交流中個體經驗的討論。這類言論不儘反映了對外部群體的負面態度，還將個體層面的經驗上升至國家層面，進一步強化民族身份認同。最後，地域仇恨言論方面，經濟發展水平、文化差異等因素影響了不同地區在網絡空間中的刻板印象構建。同時，地域言論的隱晦表達方式也較其他領域更為突出。另外，面對仇恨言論的泛濫，網絡空間中也出現了一定程度的“反仇恨言論(Counter Speech)”。本研究發現，此類言論主要表現為三種形式：邏輯反駁(如指出仇恨言論的邏輯漏洞)、積極重構(如通過溫和表達降低對立情緒)、事實回應(如提供客觀數據糾正誤解)。

從方法論角度來看，本研究採用基於統計檢驗的關鍵詞性(keyness)分析，以對數似然比(LL)為指標，從大規模語料庫中客觀識別各領域特定的(domain-specific)詞彙特徵，避免傳統研究中主觀判斷的局限性。跟單純的詞頻統計相比，LL分析能夠更精確地揭示仇恨言論在不同語境下的分布特徵，從而提高研究的可靠性和一致性。並且，本文通過關鍵詞的上下文(KWIC)分析，深入探討了關鍵詞的使用模式及其語境特徵，從而提供了更豐富的社會語義洞察。在學術層面，當前對中文仇恨言論的語言學研究仍處於起步階段，本研究通過系統分析填補了這一空白，揭示了網絡仇恨言論的表達模式，為未來相關研究奠定了方向與基礎。在實踐層面，研究成果可為互聯網內容監管、仇恨言論的自動化檢測與過濾提供有價值的參考。綜上，本研究不儘為仇恨言論的語言學分析提供了科學的方法論支撐，也為社會包容與相互理解提供了實踐指導。

## 〈參考文獻〉

- 朴敏浚 (2022). 「현대중국어 형태소 분석기의 현황과 활용」 『中國言語研究』 102, 341-372.
- (2024). 「중국 소셜미디어 크롤링과 텍스트 분석: SNS 말뭉치 기반 연구방법론의 모색」 『시민인문학』 46, 37-65.
- (2024). 「텍스트 의미 분석 시스템의 구현과 활용 -UCREL Semantic Analysis System을 중심으로-」 『인문과학연구』 38, 355-384.
- 이경진 · 하두진 · 박민준 (2023). 「텍스트 마이닝을 통해 본 시진핑 시기 중국의 전략: 후진 타오 시기와의 비교를 중심으로」 『인문사회과학연구』 31(4), 480-510.
- 林鴻飛等 (2025). 《中國計算語言學大會技術評測中文仇恨言論檢測數據》, 中文信息學會
- 饒曉俊 · 張仰森 · 賈啓龍等 (2023). <基於RoBERTa的中文仇恨言論偵測方法研究——以RoBERTa-WWM爲基礎>. 《第二十二屆中國計算語言學大會論文集》, 中文信息學會.
- 袁毓林 (2024). <ChatGPT語境下語言學的挑戰和出路>. 《現代外語》, (4).
- 袁毓林 (2024). <新文科視域下的計算社會語言學研究>. 《語言文字應用》, (1).
- Bennie, M., Zhang, D., Xiao, B., et al. (2025). PANDA - Paired Anti-Hate Narratives Dataset from Asia: Using an LLM-as-a-Judge to Create the First Chinese Counterspeech Dataset. <https://arxiv.org/abs/2501.00697>.
- Deng, J., Zhou, J., Sun, H., et al. (2022). COLD: A Benchmark for Chinese Offensive Language Detection. <https://arxiv.org/abs/2201.06025>.
- Deng, Y., Park, M., Chen, J., et al. (2022). Emotional discourse analysis of COVID-19 patients and their mental health: A text mining study. *PLoS ONE*, (9).
- Jiang, A., Yang, X., Liu, Y., et al. (2022). SWSR: A Chinese dataset and lexicon for online sexism detection. *Online Social Networks and Media*, (27).
- Rayson, P. & Garside, R. (2000). Comparing corpora using frequency profiling. In *The workshop on comparing corpora*. Online: Association for Computational Linguistics.
- Rayson, P. (2008). From key words to key semantic domains. *International Journal of Corpus Linguistics*, (4).
- Stubbs, M. (1995). Collocations and semantic profiles: On the cause of the trouble with quantitative studies. *Functions of language*, 2(1).
- Williams, K. (1976). The Failure of Pearson's Goodness of Fit Statistic. *Journal of*



*the Royal Statistical Society*, (1).

Xiao, Y., Bouamor, H. & Zaghoulani, W. (2024). Chinese Offensive Language Detection: Current Status and Future Directions. <https://arxiv.org/abs/2403.18314>.

## < ABSTRACT >

This study systematically analyzes Chinese online hate speech based on a large-scale corpus. Using the Log-Likelihood Ratio (LL), we extract keyword features across three domains: gender, race/nationality, and region. By integrating Keyword-in-Context (KWIC) analysis, the study examines the contextual characteristics and socio-cultural implications of hate speech. The findings reveal that gender-related hate speech reinforces gender antagonism through keywords such as *zhinanai* (misogynistic straight men) and *lucha* (cunning women). Racial hate speech exhibits a strong collectivist tendency, primarily addressing discrimination against Chinese people by foreign groups. Regional hate speech is shaped by economic, cultural, and political factors, with long-standing stereotypes influencing different patterns of expression. This study employs a keyword analysis approach based on statistical hypothesis test, overcoming the limitations of traditional subjective keyword identification, improving research reliability and consistency, and providing a scientific foundation for online hate speech regulation.

主題語(Key words) : Hate speech, keyness, Log-Likelihood Ratio (LL), Keyword in Context (KWIC), corpus linguistics

|         |               |       |               |
|---------|---------------|-------|---------------|
| 투고(접수)일 | 2025년 10월 30일 | 심 사 일 | 2025년 11월 18일 |
| 수 정 일   | 2025년 11월 30일 | 게재확정일 | 2025년 12월 16일 |

中國語文學論集 Vol. 155 (2025.12.31), 55-71  
<http://dx.doi.org/10.25021/JCLL.2025.12.155.71>